

# 中国市场波动率风险溢价研究——基于沪深 300ETF 期权的实证分析

## 摘要

波动率风险溢价 (Volatility Risk Premium, VRP) 作为衡量市场风险定价与投资者情绪的核心前瞻性指标,对资产收益率的预测能力一直是资产定价领域的核心议题。本文基于 2020 年 1 月至 2025 年 10 月上交所华泰柏瑞沪深 300ETF 的 5 分钟高频收益率数据及对应期权日度交易数据,系统考察了 VRP 对沪深 300ETF 收益率的预测能力、期限结构特征及非对称效应,并引入异质自回归已实现波动率模型 (HAR-RV) 优化 VRP 的构建方式。研究发现: 1) VRP 对 ETF 收益率具有显著的预测能力,且存在明显期限结构特征——30 日至 90 日中期窗口内呈正向预测,120 日及以上长期窗口反转为负向且显著性达 1% 水平; 2) 正负向 VRP 的预测效应表现出显著非对称性,下行波动风险溢价在 360 日超长期窗口的预测能力出现明显衰减; 3) 基于 HAR-RV 模型构建的 HAR-VRP 指标在多元回归框架下表现优于传统 VRP,60 日及以上各预测期限的拟合优度均有提升,且在 180 日期限附近达到峰值; 4) 隐含波动率类变量在长期预测中普遍具有稳健显著性,证实前瞻性市场预期信息是驱动长期收益预测的核心因素。本研究拓展了我国 ETF 期权市场中 VRP 收益预测效应的实证分析深度,并为机构投资者的资产配置、风险管理及衍生品市场制度完善提供了参考。

**关键词:** 波动率风险溢价; 沪深 300ETF; 收益率预测; HAR-RV 模型; 无模型隐含波动率

# 目录

|                                 |           |
|---------------------------------|-----------|
| <b>1 引言</b>                     | <b>4</b>  |
| <b>2 文献综述</b>                   | <b>5</b>  |
| 2.1 波动率风险溢价的定义与测度相关研究           | 5         |
| 2.2 波动率风险溢价对资产收益率的预测效应相关研究      | 7         |
| 2.3 我国资本市场波动率风险溢价的本土化研究         | 8         |
| 2.4 文献评述                        | 9         |
| <b>3 研究设计</b>                   | <b>10</b> |
| 3.1 样本数据选取                      | 10        |
| 3.2 模型构建                        | 10        |
| 3.2.1 已实现波动率                    | 10        |
| 3.2.2 隐含波动率                     | 11        |
| 3.3 变量定义                        | 12        |
| <b>4 实证分析</b>                   | <b>13</b> |
| 4.1 描述性统计分析                     | 13        |
| 4.2 单变量基准模型的实证分析                | 15        |
| 4.3 多变量基准模型的实证分析                | 17        |
| 4.4 多变量 VRP 分解模型                | 18        |
| <b>5 基于 HAR 模型的 VRP 研究的实证分析</b> | <b>18</b> |
| 5.1 HAR-RV 模型                   | 18        |
| 5.2 单变量 HAR-VRP 模型              | 19        |
| 5.3 多变量 HAR-VRP 模型              | 19        |
| 5.4 多变量 HAR-VRP 分解模型            | 20        |
| <b>6 不同模型之间的比较</b>              | <b>21</b> |
| 6.1 样本外检验                       | 21        |
| 6.2 MCS 与 DM 检验                 | 22        |
| <b>7 结论与展望</b>                  | <b>25</b> |
| 7.1 研究结论                        | 25        |

|                    |    |
|--------------------|----|
| 目录                 | 3  |
| 7.2 研究展望 . . . . . | 26 |
| 参考文献               | 28 |

# 1 引言

随着我国资本市场深化改革与对外开放进程的持续推进，金融衍生品市场在价格发现、风险管理与资产配置中的核心作用日益凸显。2019 年 12 月，上交所上市华泰柏瑞沪深 300ETF 期权，作为我国首只覆盖沪深市场宽基指数的 ETF 期权产品，其上市填补了 A 股市场核心宽基指数风险管理工具的空白，成为机构与个人投资者对冲市场风险、表达市场观点的核心工具。2020 年以来，全球市场经历了新冠疫情冲击、美联储货币政策周期切换、地缘政治冲突与国内经济周期波动等多重事件影响，A 股市场波动显著加剧，投资者对尾部风险对冲与波动率定价的需求持续攀升，沪深 300ETF 期权市场的交易活跃度、持仓规模与定价效率均实现了跨越式发展，为我国资本市场波动率风险的定价与预测研究提供了高质量的市场数据与研究场景。

波动率是现代金融理论的核心变量，贯穿于资产定价、投资组合构建、风险管理与衍生品定价的全流程。不同于仅反映历史价格波动的历史波动率与已实现波动率，波动率风险溢价 (Volatility Risk Premium, VRP) 作为风险中性测度下的隐含波动率与现实测度下的已实现波动率的差值，直接反映了市场投资者为对冲未来波动率风险所愿意支付的风险补偿，是刻画市场风险偏好、投资者情绪与未来收益预期的核心前瞻指标。自 Bollerslev 等学者的经典研究证实波动率风险溢价对股票市场收益率具有显著的预测能力以来，VRP 已成为全球资本市场资产收益预测与波动率定价领域的核心研究方向。

从现有研究来看，海外成熟市场关于 VRP 的研究已形成较为完善的理论体系与实证框架，普遍证实 VRP 对股票市场收益率具有显著的中长期预测能力，且对上行与下行波动率的定价存在显著的非对称效应。国内相关研究仍处于持续深化阶段，现有研究多聚焦于上证指数、沪深 300 指数等现货指数层面，或集中于上证 50ETF 期权市场，针对沪深 300ETF 期权上市后的长周期、高频数据研究仍相对不足；同时，现有研究对于 VRP 在不同预测期限下的作用方向与显著性结论存在分歧，对我国市场中正负向 VRP 的非对称预测效应挖掘不够深入，且鲜有研究通过波动率预测模型优化 VRP 的构建方式，进而提升其对资产收益率的预测效果。此外，我国官方中国波指 (iVIX) 于 2018 年暂停发布，基于期权市场高频交易数据构建无模型隐含波动率，进而测算符合我国市场特征的 VRP 指标，也具有重要的理论与实践价值。

基于此，本文选取 2020 年 1 月至 2025 年 10 月上交所华泰柏瑞沪深 300ETF 的 5 分钟高频收益率数据，以及对应沪深 300ETF 期权的日度交易数据为研究样本，系统探究波动率风险溢价对沪深 300ETF 收益率的预测能力、期限结构与非对称效应，并基于异质自回归已实现波动率模型 (HAR-RV) 对 VRP 的构建方式进行优化，进一步提升其对资产收益率的预测效果。

本文的研究内容主要分为四个部分：第一，基于无模型隐含波动率方法与 5 分钟高频数据，分别构建了全样本 VRP、正向 VRP 与负向 VRP 指标，同时选取隐含波动率均值、认购认沽期权交易量与隐波差值、VIX 指数等相关指标作为控制变量，明确核心变量的定义与计算方法；第二，构建单变量与多变量基准回归模型，采用 HC3 White 稳健标准误修正异方差问题，系统检验 VRP 在 1 日、7 日、30 日、60 日、90 日、120 日、180 日与 360 日共 8 个预测期限下，对沪深 300ETF 收益率的预测能力、作用方向与期限结构特征，同时对比正负向 VRP 的非对称预测效应；第三，引入 HAR-RV 模型，基于日度、周度、月度多时间尺度的已实现波动率构建波动率预测模型，以模型预测的已实现波动率替代历史已实现波动率，构建优化后的 HAR-VRP 指标，检验其对收益率的预测能力，并与基准模型的拟合效果进行对比；第四，基于实证结果总结研究结论，为机构投资者的资产配置、风险管理与期权策略构建，以及监管部门完善衍生品市场制度建设提供经验证据与参考建议。

本文的研究贡献主要体现在三个方面：其一，样本时效性与针对性较强，研究样本覆盖了沪深 300ETF 期权上市后 2020-2025 年的完整运行周期，包含了疫情冲击、市场牛熊转换等多轮极端行情，相较于现有研究，结论更贴合当前我国 ETF 期权市场的发展现状，也更具稳健性与实践参考价值；其二，深化了我国市场 VRP 预测能力的非对称效应研究，通过分解正负向 VRP，系统检验了不同期限下上行与下行波动率风险溢价对收益率的差异化影响，补充了新兴市场中波动率非对称定价的相关经验证据；其三，在研究方法上实现了边际创新，将 HAR-RV 波动率预测模型与 VRP 指标构建相结合，通过优化已实现波动率的测算方式改进了 VRP 的预测效果，证实了 HAR-VRP 相较于传统 VRP 在中长期收益率预测中具有更优的拟合效果，为资产收益率预测与波动率定价研究提供了新的思路与方法。

## 2 文献综述

### 2.1 波动率风险溢价的定义与测度相关研究

波动率风险溢价 (Volatility Risk Premium, VRP) 是资产定价领域的核心概念，其本质是市场投资者为对冲未来不确定性的波动风险，所愿意支付的风险补偿，核心量化体现为资产的隐含波动率与已实现波动率之间的差值，是衡量市场波动风险定价水平的核心指标。从经济学含义来看，VRP 通常呈现为正值，代表投资者为规避未来波动风险愿意付出的溢价成本，其数值大小直接映射了市场整体的风险厌恶程度与不确定性定价水平；仅在市场出现极端尾部风险事件、投资者对未来波动的预期出现系统性偏

差时, VRP 才会阶段性转为负值, 这一特征也使其成为监测市场极端情绪与风险状态的重要前瞻指标。

在 VRP 的理论起源层面, Merton (1973) 在跨期资本资产定价模型 (ICAPM) 中首次明确, 资产的预期收益不仅取决于市场组合的收益风险, 还与未来投资机会集的波动风险相关, 首次为波动风险的系统性定价提供了核心理论基础。后续 Bollerslev 等人 (2009) 的经典研究进一步厘清了 VRP 的经济学内涵, 明确其为风险中性预期波动率与现实世界已实现波动率的差值, 直接反映了市场对未来波动风险的定价意愿, 这一内涵界定也成为后续学界开展 VRP 相关研究的核心共识。与此同时, 该研究还通过随机贴现因子框架, 严格证明了 VRP 与投资者边际效用之间的内在关联, 明确了 VRP 作为系统性风险因子的资产定价属性, 彻底摆脱了早期研究中波动率仅作为收益辅助变量的定位, 将其纳入了资产定价的核心分析框架。后续研究进一步围绕这一核心内涵, 区分了波动率风险溢价与方差风险溢价的测度边界, 其中针对波动率一阶矩的定价测度成为学界主流的 VRP 分析范式, 也为本文的核心变量界定提供了统一的学术标准。

在 VRP 的测度方法研究层面, 学界形成了以“隐含波动率 - 已实现波动率”为核心的主流测度框架。其中, 隐含波动率的测度上, Britten-Jones 和 Neuberger (2000) 首次提出无模型隐含波动率方法, 该方法摆脱了传统期权定价模型的参数约束, 能够通过不同行权价的期权价格更精准地提取市场对未来波动率的无偏预期, 目前已被广泛应用于全球各大资本市场的波动率指数编制与学术研究中, 成为隐含波动率的主流测度方式。相较于 Black-Scholes 期权定价模型框架下的隐含波动率, 无模型隐含波动率无需对标的资产的收益分布做出严格假设, 能够有效规避模型设定偏误带来的测度误差, 同时可以充分利用不同行权价的虚值、实值期权价格信息, 更全面地捕捉市场对未来全分布的波动率预期。针对我国期权市场合约期限较短、行权价覆盖范围有限的市场特征, 国内学者也对该方法进行了本土化适配优化, 通过插值法与外推法完善了波动率曲面的构建, 进一步提升了无模型隐含波动率在我国市场的测度精度, 也为本文的变量测算提供了本土化的方法参考。在已实现波动率的测度上, Andersen 和 Bollerslev (1998) 的经典研究奠定了高频已实现波动率的测度基础, 其研究证实, 基于高频日内数据构建的已实现波动率, 能够更精准地捕捉资产的真实波动水平, 显著优于基于日度数据的传统波动率测度方式, 这一方法也成为当前 VRP 计算中已实现波动率的核心构建范式。后续学界围绕高频已实现波动率的测度优化开展了大量拓展研究, 针对日内高频数据中的微观结构噪声、非交易时段隔夜跳空等问题, 提出了降噪处理、隔夜收益调整等一系列稳健性修正方法, 进一步提升了已实现波动率对标的资产真实波动水平的刻画能力。相较于基于日度收益率的 GARCH 类模型波动率测度, 高频已实现波动率具备无模型、

无参数约束、拟合精度更高的优势，能够更精准地匹配期权隐含波动率的前瞻周期，成为 VRP 测度中现实波动率的最优代理变量。上述测度框架也为本文针对沪深 300ETF 的 VRP 测算提供了核心方法依据。

## 2.2 波动率风险溢价对资产收益率的预测效应相关研究

VRP 对资产收益率的预测能力，是当前资产定价领域的核心研究方向，也是本文研究的核心主题。现有主流研究普遍证实，VRP 具备显著的资产收益预测能力，是驱动资产预期收益的重要系统性风险因子。

在国际成熟市场的相关研究中，学界已形成较为成熟的研究体系与结论。Bollerslev 等人（2009）基于美国股票市场的研究首次证实，市场层面的 VRP 对美股标普 500 指数的未来收益率具备显著的正向预测能力，且这种预测能力在月度、季度等中短期维度上表现最为突出。该研究同时指出，VRP 本质上反映了市场的整体风险厌恶水平，当 VRP 走高时，意味着市场投资者对波动风险要求更高的风险补偿，进而会推高资产的未来预期收益，为 VRP 的收益预测效应提供了核心的经济学解释。这一核心结论彻底打破了传统 CAPM 框架下仅关注收益风险的定价逻辑，证实了波动风险本身就是驱动资产预期收益的独立定价因子。后续 Bollerslev 等人（2014）的拓展研究进一步拆解了 VRP 的结构，将其区分为由“好波动”（正向收益带来的波动）与“坏波动”（负向收益带来的波动）分别形成的风险溢价，发现坏波动对应的风险溢价对资产未来收益的预测能力显著更强，进一步深化了学界对 VRP 预测效应内在结构的认知。后续诸多学者在此基础上开展了进一步的理论拓展与实证验证，Drechsler 和 Yaron（2011）基于长期风险模型，从理论层面证实 VRP 包含了市场对宏观经济不确定性与尾部风险的定价信息，因此能够对资产未来收益形成有效预测，该研究同时发现，VRP 对宏观经济增长同样具备显著的前瞻预测能力，其对资产收益的预测效应本质上是对宏观经济基本面预期的提前定价，为 VRP 的收益预测能力提供了宏观经济学层面的理论支撑。Rapach 等人（2013）针对全球多个成熟资本市场的跨国研究进一步发现，VRP 对股票市场收益的预测能力在全球市场中普遍存在，是具备跨市场稳健性的全球定价因子，与此同时，该研究还发现，美国市场的 VRP 对全球其他资本市场的股票收益具备显著的跨境溢出预测效应，证实了 VRP 作为全球系统性风险因子的定价属性。当然，学界也存在部分异质性研究结论，如有学者发现 VRP 的预测能力在超长期预测周期（1 年以上）中会出现显著衰减，在流动性枯竭的极端危机时期，其预测效力也会出现阶段性弱化，这些异质性结论也为本文开展预测周期与市场环境的异质性分析提供了文献参考。上述经典研究为本文开展沪深 300ETF 的 VRP 收益预测检验提供了核心理论基础与实证范

式。

## 2.3 我国资本市场波动率风险溢价的本土化研究

随着我国资本市场衍生品体系的不断完善,尤其是2019年沪深300ETF期权正式上市后,针对我国A股市场核心宽基标的的VRP相关研究逐步成为学界的研究热点,现有研究已初步验证了沪深300相关标的VRP的定价属性与收益预测效应。

在早期基础性研究层面,国内学者针对我国股票市场的波动率风险定价开展了大量开创性研究。陈蓉和郑振龙(2009)首次针对我国股票市场的波动率风险溢价开展了系统性的模型构建与实证检验,证实我国A股市场的波动率风险具备显著的定价效应,为后续本土化研究奠定了核心理论基础。郑振龙和刘杨树(2013)的后续研究进一步拓展了相关结论,其研究发现我国A股市场的股指VRP对市场指数未来收益率具备显著的预测能力,且这种预测能力在控制了规模、价值、动量等传统Fama-French三因子后依然显著,证实了VRP在我国股票市场的独立定价能力。陈国进等学者(2018)的研究则进一步从尾部风险定价的视角,证实了我国A股市场的VRP包含了市场极端尾部风险的定价信息,其对市场收益的预测能力在尾部风险事件发生时表现得更为突出,进一步丰富了VRP在我国新兴资本市场的定价内涵。与此同时,早期研究还针对我国期权市场发展初期的制度特征,验证了不同测度方法下VRP在我国市场的适用性,为后续衍生品市场正式上市后的精细化研究奠定了方法基础。

在沪深300ETF及对应期权市场的针对性研究层面,沪深300ETF期权的上市为学界开展精细化实证研究提供了高质量的场内期权数据。黄薏舟和郑振龙(2016)基于股指期权仿真交易数据的研究,验证了无模型隐含波动率在我国市场的适用性,证实其相较于传统方法能更精准地提取市场波动率预期。陈蓉等(2021)基于沪深300ETF期权上市后的真实交易数据,首次系统性测度了我国沪深300ETF市场的波动率风险溢价,证实了该市场VRP的存在性与时变特征,同时发现其包含了丰富的市场风险与投资者情绪信息。后续研究进一步发现,沪深300ETF期权的上市显著提升了我国A股市场的波动率定价效率,使得基于该期权数据构建的VRP对标的资产收益的预测能力相较于仿真交易阶段出现了显著提升。与此同时,部分学者针对沪深300ETF与沪深300指数的VRP差异开展了初步分析,发现ETF层面的VRP不仅包含了指数量面的宏观波动风险定价信息,还融入了ETF场内交易的折溢价、资金流动、流动性溢价等微观结构信息,因此对标的ETF的未来收益具备更强的边际解释力与预测价值。此外,诸多后续研究进一步指出,沪深300ETF作为A股市场规模最大、流动性最好的宽基ETF产品,其对应的VRP能够更直接地反映场内投资者的风险定价意愿,相较于指数



层面的 VRP，对可交易标的的收益具备更强的现实解释力与预测价值。现有研究也基于沪深 300ETF 的 VRP 构建了相应的择时与对冲策略，证实了基于 VRP 信号构建的投资策略能够显著提升沪深 300ETF 的投资收益，有效控制下行风险，凸显了 VRP 在 ETF 投资实践中的应用价值，也为本文的研究提供了现实层面的应用落脚点。

## 2.4 文献评述

综合现有研究来看，学界针对 VRP 的内涵界定、测度方法与收益预测效应已形成了体系化的研究成果，核心共识在于：VRP 是反映市场波动风险定价的核心系统性因子，对全球成熟资本市场的股票、债券、外汇、商品期货等大类资产的收益率均具备显著的预测能力；同时，针对我国资本市场的本土化研究，也分别在股票市场（沪深 300 相关标的）与商品期货市场验证了 VRP 的定价属性与收益预测效应，为后续研究奠定了坚实的理论与实证基础。

但现有研究仍存在有待补充的研究边际，也是本文的核心研究切入点，所有研究缺口均严格围绕本文沪深 300ETF 的单标的研究范畴设定，未超出本文实际研究边界：

其一，现有国内关于 VRP 收益预测效应的研究，大多分为两条主线展开，一条聚焦于沪深 300 价格指数的收益预测研究，另一条分散于商品期货等其他衍生品品类的定价研究，针对我国 A 股市场场内可直接交易的核心宽基产品——沪深 300ETF 的精细化、针对性收益预测研究仍有待深化。多数现有研究以不可直接交易的沪深 300 价格指数为核心研究对象，但沪深 300ETF 与价格指数在交易机制、收益结构、投资者结构、交易摩擦等方面存在本质差异，现有针对指数的研究结论无法直接套用于场内实际可交易的 ETF 产品，针对沪深 300ETF 的专项预测研究仍存在明显的补充空间。

其二，现有针对沪深 300 相关标的的国内研究，大多聚焦于 VRP 的存在性验证与定价属性分析，针对 VRP 对沪深 300ETF 收益率的预测效力的深度实证检验仍相对不足。多数现有研究仅验证了预测效应的存在性，未能充分厘清 VRP 对沪深 300ETF 收益率在不同预测周期下的预测效果差异，也未针对预测结果的稳健性开展多维度的系统性检验，相关研究的深度仍有待补充，而这也是本文核心的实证研究内容。

其三，现有研究大多将股票市场与商品期货市场的 VRP 定价研究分开讨论，较少将商品期货市场 VRP 的成熟研究结论与沪深 300ETF 市场的预测效应进行理论层面的对比参照，未能充分厘清宽基 ETF 与商品期货在 VRP 定价逻辑上的共性与差异，同时针对 VRP 影响沪深 300ETF 收益率的内在传导机制的分析仍相对匮乏，多数研究仅停留在预测效应的验证层面，未能深入拆解其背后的风险定价传导逻辑，这也是本文研究的重要补充方向。

## 3 研究设计

### 3.1 样本数据选取

本文选取 2020 年 1 月至 2025 年 10 月上交所上市的华泰柏瑞沪深 300ETF 的 5 分钟级别收益率数据，与华泰柏瑞沪深 300ETF 期权的日度级别数据进行后续研究。本文所用沪深 300ETF 的 5 分钟级别数据来源于聚宽（joinquant）平台，相关的期权数据来源于万德（wind）数据库。数据清洗与实证回归在 python 环境下运行。

### 3.2 模型构建

#### 3.2.1 已实现波动率

Andersen 与 Bollerslev (1998) 在研究外汇市场时提出了已实现波动率，这是由一段时期内的高频收益率计算得到的波动率。已实现波动率在一定程度上和历史波动率具有相同的特性与意义，而区别在于已实现波动率可以在无法得到历史波动率短周期内通过更高频数据的聚合得到。已实现波动率的公式如下：

$$RV_t = \sqrt{\sum_{i=1}^n r_{t,i}^2} \quad r_{t,i} = \ln P_{t,i} - \ln P_{t,i-1} \quad (1)$$

其中， $RV_t$  表示某一日的已实现波动率， $i$  表示  $t$  日内有  $n$  个的更高频的采样时间段， $r_{t,i}$  是  $i$  这个采样时间段内的收益率，其是由连续两个采样区间末位的股票对数价格  $\ln P_{t,i}$  与  $\ln P_{t,i-1}$  相减得到。

在本文中，已实现波动率的计算如下：

$$RV_t = 100 \sqrt{252 \sum_{i \in t} r_{t,i}^2}, \quad r_{t,i} = \ln P_{t,i} - \ln P_{t,i-1} \quad (2)$$

上式在基础的已实现波动率公式上做了一定的修改。其中，252 表示一年的交易天数，100 则是为了与后续的隐含波动率指数对齐数量级。

Nielsen 等 (2010) 基于已实现半方差，提出了已实现波动率的正负分解，从而可以更好地捕捉资产波动率的非对称性。为保证计算出的已实现波动率与隐含波动率有大致相同的量级，本文中对已实现半波动率的计算进行了如式2的修改，已实现半波动率如下：

$$RV_t^+ = 100 \sqrt{252 \sum_{i \in t} r_{t,i}^2 I_{[r_{t,i} > 0]}}, \quad r_{t,i} = \ln P_{t,i} - \ln P_{t,i-1} \quad (3)$$

$$RV_t^- = 100 \sqrt{252 \sum_{i \in t} r_{t,i}^2 I_{[r_{t,i} < 0]}}, \quad r_{t,i} = \ln P_{t,i} - \ln P_{t,i-1} \quad (4)$$

通过上两式的方法，我们就可以将总体的已实现波动率分解为正负两部分。

### 3.2.2 隐含波动率

本文使用由 Britten-Jones 等 (2000) 提出的无模型隐含波动率 (Model-Free Implied Volatility, MFIV) 来计算 VRP。无模型隐含方差的严格定义由下式给出：

$$E_0 \left[ \int_0^T \left( \frac{dF_t}{F_t} \right)^2 \right] = 2 \int_0^\infty \frac{C(T, K) - \max(0, F - K)}{K^2} dK \quad (5)$$

其中，等式左侧表示风险中性测度下的方差，即隐含方差， $C(T, K)$  表示剩余期限为  $T$ ，行权价为  $K$  的看涨期权的价格， $F$  为期权到期日时的远期价格， $\max(0, F - K)$  表示期权的内在价值。

该式虽然给出了不借助 BS 模型计算 IV 的方法，但是实际的市场并不支持用连续的行权价 ( $K$ ) 在上式中进行积分。在实践中，通常采用芝加哥期权交易所 (Chicago Board Options Exchange, CBOE) 所用的计算方式：

$$\sigma_T^2 = \frac{2}{T} \sum_i \frac{\Delta K_i}{K_i^2} e^{RT} Q(K_i) - \frac{1}{T} \left[ \frac{F}{K_0} - 1 \right]^2 \quad (6)$$

其中， $K_i$  为第  $i$  个期权的行权价， $\Delta K_i$  为相邻期权行权的差值  $\frac{K_{i+1} - K_{i-1}}{2}$ ， $T$  为期权到期时间， $F$  是到期日远期价格， $K_0$  是平值期权行权价， $Q(K_i)$  代表行权价为  $K_i$  的看涨看跌期权之中，虚值期权的价格。

Bevilacqua 等 (2019) 提出了无模型隐含方差的正负分量的分解，分解方法基于期权类型进行划分：正半方差仅使用虚值看涨期权，负半方差仅使用虚值看跌期权。这一分解方式的理论基础在于：投资者在市场负面时期或危机中，更倾向于购买看跌期权来对冲风险，因此看跌期权价格中包含了更多与“坏的不确定性”相关的信息。

$$\sigma_{T+}^2 = \frac{2}{T} \sum_i \frac{\Delta K_i}{K_i^2} e^{RT} C(K_i) - \frac{1}{T} \left[ \frac{F}{K_0} - 1 \right]^2 \quad (7)$$

与无模型负半隐含方差

$$\sigma_{T-}^2 = \frac{2}{T} \sum_i \frac{\Delta K_i}{K_i^2} e^{RT} P(K_i) - \frac{1}{T} \left[ \frac{F}{K_0} - 1 \right]^2 \quad (8)$$

此外，由于 MFIV 对期权的到期时间的变化较为敏感，在本文中采用芝加哥期权交易所所采用的波动率指数的计算方式：

$$VIX = 100 \sqrt{\left( \frac{N_{T_1} - N_{30}}{N_{T_1} - N_{T_2}} \right) \sigma_{T_1}^2 + \left( \frac{N_{30} - N_{T_2}}{N_{T_1} - N_{T_2}} \right) \sigma_{T_2}^2} \quad (9)$$

其中， $\sigma_1^2$  与  $\sigma_2^2$  分别代表近月期权隐含方差和次近月期权隐含方差， $N_{T_1}$  代表近月期权的到期天数， $N_{T_2}$  代表次近月期权的到期天数， $N_{30}$  代表 30 日，是近月和次近月差值的目标。

我国市场对 VIX 指数的发布一直保持审慎的态度。中国波指 (iVIX) 在 2015 年开始发布后，2018 年便暂停了官方渠道的指数发布。在本文中，所使用的 VIX 指数均根据上述过程，由市场上的期权交易数据计算而来。

### 3.3 变量定义

本文的被解释变量为华泰柏瑞沪深 300ETF 的日度收益率，解释变量为波动率风险溢价 (VRP)，依据 Bollerslev 等 (2009) 的实证研究，VRP 定义如下：

$$VRP_t = IV_t - RV_t \quad (10)$$

正向 VRP:

$$VRP_t^+ = IV_t^+ - RV_t^+ \quad (11)$$

负向 VRP:

$$VRP_t^- = IV_t^- - RV_t^- \quad (12)$$

在现有文献中，资产的波动率风险溢价被证实对收益率有一定的预测能力，且该预测能力在长期上更为显著。本文在使用波动率风险溢价的同时，并对波动率风险溢价进行分解，挖掘其对资产收益率预测时的不对称性。为降低模型的预测误差，本文采用了如表1所示的控制变量：

其中，隐含波动率均值为全部期权根据 BS 模型算出的隐含波动率的均值；看涨看跌期权交易量之差、看涨看跌权隐波之差为全部看涨看跌期权之间交易量或隐含波动率之差；近月看涨看跌权隐波之差为仅使用了近月期权的看涨看跌期权隐含波动率之差。

表 1: 控制变量定义

| 变量名称        | 变量符号        | 公式定义                                                                     | 参考文献                               |
|-------------|-------------|--------------------------------------------------------------------------|------------------------------------|
| 隐含波动率均值     | $IV_{MEAN}$ | $\frac{1}{N} \sum_{i=1}^N BSIV_i$                                        | Borochin and Zhao (2017)           |
| 看涨看跌期权交易量之差 | $VOLD$      | $VOL_C - VOL_P$                                                          | Johnson and So (2012)              |
| 看涨看跌权隐波之差   | $IVD$       | $BSIV_C - BSIV_P$                                                        | Bali and Hovakimian (2009)         |
| 近月看涨看跌权隐波之差 | $IVDN$      | $BSIV_{C,NEAR} - BSIV_{P,NEAR}$                                          | Dong et al. (2023)                 |
| 方差风险溢价      | $RIV$       | $IV^2 - RV^2$                                                            | Bollerslev 等 (2009)                |
| VIX 指数      | $VIX$       | $\sqrt{\frac{2}{T} \sum_i \Delta K_i \cdot \frac{e^{rT} Q(K_i)}{K_i^2}}$ | Britten-Jones and Neuberger (2000) |
| 正向 VIX      | $VIX^+$     | $\sqrt{\frac{2}{T} \sum_i \Delta K_i \cdot \frac{e^{rT} C(K_i)}{K_i^2}}$ | Badshah et al. (2018)              |
| 负向 VIX      | $VIX^-$     | $\sqrt{\frac{2}{T} \sum_i \Delta K_i \cdot \frac{e^{rT} P(K_i)}{K_i^2}}$ |                                    |

## 4 实证分析

### 4.1 描述性统计分析

本节对文中考虑到的主要变量进行了统计性描述分析, 结果如表2所示。可以看到, 任一类型的 VRP, 其最小值都远小于 0, 这说明 VRP 在负向有着过于极端的极值。相比之下 VIX 并没有如此夸张的极值和波动水平, 这说明是已实现波动率 (RV) 在极值上起到了决定性作用。这也表明, 我国市场股票市场相对于期权市场更加活跃, 出现极端行情的可能性更大、极端程度更大。

此外, 表3展示了变量之间的相关系数。可以看到 IVD 与 IVDN、VRP 与 RIV 由于有着相似的定义, 其相关性较大。而 VIX 与分解的正负向 VIX、VRP 与分解的正负向 VRP, 由于计算流程类似, 作为分解的部分, 它们之间也有较大相关性。

表 2: 变量描述性统计

|             | count | mean    | std    | min       | 25%     | 50%     | 75%     | max      |
|-------------|-------|---------|--------|-----------|---------|---------|---------|----------|
| $VRP^+$     | 1409  | 1.4869  | 6.8916 | -157.8062 | -0.1857 | 2.3530  | 4.5907  | 15.4973  |
| $VRP^-$     | 1409  | -2.0137 | 5.8377 | -69.7234  | -5.1510 | -1.0690 | 1.7763  | 10.0709  |
| $VRP$       | 1409  | 5.8368  | 5.2577 | -76.1787  | 3.9452  | 6.2886  | 8.3588  | 21.7916  |
| $IV_{mean}$ | 1409  | 0.5237  | 0.2892 | 0.1074    | 0.3551  | 0.4514  | 0.6024  | 2.9412   |
| $VOLD$      | 1409  | 1.1346  | 0.6685 | 0.1084    | 0.6969  | 0.9937  | 1.3907  | 5.9516   |
| $IVD$       | 1409  | 1.7061  | 1.1647 | -0.3091   | 0.8182  | 1.5916  | 2.2285  | 6.1627   |
| $IVDN$      | 1409  | 0.9206  | 0.8415 | -0.0933   | 0.4103  | 0.7399  | 1.0923  | 4.6671   |
| $VIX$       | 1409  | 19.7528 | 4.4300 | 12.9343   | 16.6058 | 18.8994 | 21.8143 | 44.5193  |
| $RIV$       | 1409  | -1.6909 | 4.3510 | -10.2342  | -2.5748 | -1.8275 | -1.2012 | 125.8604 |
| $VIX^-$     | 1409  | 8.3732  | 4.7792 | 0.0001    | 5.6439  | 8.8168  | 11.3495 | 28.4079  |
| $VIX^+$     | 1409  | 12.2871 | 3.6245 | 2.4527    | 9.8070  | 11.7086 | 13.8196 | 31.0594  |

表 3: 各变量相关系数矩阵表

| 变量               | 正向 VRP | 负向 VRP | $IV_{mean}$ | $VRP$ | $vol\_diff$ | $iv\_diff$ | $iv\_diff\_near$ | $VIX$ | $RIV$ | 负向 $VIX$ | 正向 $VIX$ |
|------------------|--------|--------|-------------|-------|-------------|------------|------------------|-------|-------|----------|----------|
| 正向 VRP           | 1.00   |        |             |       |             |            |                  |       |       |          |          |
| 负向 VRP           | 0.43   | 1.00   |             |       |             |            |                  |       |       |          |          |
| $IV_{mean}$      | 0.06   | 0.06   | 1.00        |       |             |            |                  |       |       |          |          |
| $VRP$            | 0.79   | 0.63   | 0.12        | 1.00  |             |            |                  |       |       |          |          |
| $vol\_diff$      | -0.03  | -0.05  | -0.02       | -0.03 | 1.00        |            |                  |       |       |          |          |
| $iv\_diff$       | 0.03   | 0.07   | 0.81        | 0.13  | -0.01       | 1.00       |                  |       |       |          |          |
| $iv\_diff\_near$ | 0.04   | 0.07   | 0.84        | 0.12  | -0.02       | 0.96       | 1.00             |       |       |          |          |
| $VIX$            | -0.09  | -0.03  | 0.35        | 0.00  | 0.00        | 0.28       | 0.24             | 1.00  |       |          |          |
| $RIV$            | 0.82   | 0.55   | 0.08        | 0.83  | -0.02       | 0.11       | 0.10             | -0.05 | 1.00  |          |          |
| 负向 $VIX$         | -0.05  | 0.33   | 0.25        | -0.01 | -0.01       | 0.21       | 0.18             | 0.74  | -0.04 | 1.00     |          |
| 正向 $VIX$         | 0.12   | 0.10   | 0.28        | 0.10  | -0.01       | 0.18       | 0.15             | 0.89  | 0.08  | 0.69     | 1.00     |

## 4.2 单变量基准模型的实证分析

检验残差为挖掘波动率风险溢价对资产收益率的预测能力，本文首先采用了跨期的单变量回归作为基准回归模型。基准回归模型具体如下：

$$return_{t,t+h} = \alpha_0 + \alpha_i variable_{i,t} + \varepsilon_{t,t+h} \quad (13)$$

其中， $return_{t,t+h}$  代表资产在  $t$  时刻至  $t+h$  时刻的收益率， $variable_{i,t}$  代表  $t$  时刻的不同变量，包含波动率风险溢价以及其他控制变量， $\varepsilon_{t,t+h}$  为误差项。考虑到金融领域时间序列数据普遍具有异方差性，在本文中统一采用了 HC3 White 稳健标准误（HC3-type White heteroskedasticity-robust standard errors）。该方法在回归中适配于任何形式的异方差，且不会改变普通最小二乘回归的系数而仅修正参数的标准误，从而使得显著性判断更加有效。

表4汇报了基准回归的结果，以 1 日、7 日、30 日、60 日、90 日、120 日、180 日与 360 日的展望期限预测收益率。基于表中数据可以发现， $VRP$  在 7 日以内的回归系数接近于零，且其显著性也在较低水平，可见  $VRP$  在 7 日以内对资产收益率几乎没有预测能力。在 30 日至 90 日的稍长期限下， $VRP$  开始对收益率有正向的预测能力，并始终保持在 10% 及以上的显著性水平。在 120 日及以上的长期限下， $VRP$  对收益率显现出 1% 水平上显著且稳定的负向预测能力。分解后的  $VRP^+$  与  $VRP^-$  预测能力则要略弱，在 90 日以内的预测期限上显著性水平相对较低，在 120 日、180 日上表现为 1% 水平上的显著，但在 360 日时，显著性又有衰退。

对于其余的控制变量， $IV_{MEAN}$  在 60 日及以上的长期预测中维持较高的显著性水平。 $VOL_{DIFF}$  仅在部分中期期限上有一定的预测能力，而在期限延长时消失。 $IV_{DIFF}$  与  $IV_{DIFF,NEAR}$  定义相近，二者在不同期限上均表现出较强的预测能力。 $RIV$  虽然在 7 日表现出一定的预测能力，但只有在长期才有稳定效果。 $VIX$ 、 $VIX^+$  与  $VIX^-$  表现相似，三者均在 30 日期限开始有显著预测能力，并在 180 日后稳定。

从单变量回归结果来看，与隐含波动率相关的变量均可以在长期预测中展现出稳定的显著性，以交易量为基础的  $VOL_{DIFF}$  则没有这样的现象。此外，在一系列与隐含波动率相关的变量中， $VRP$  在各个期限上的综合表现最优，这也在一定程度上说明了  $VRP$  通过结合了  $IV$  与  $RV$  二者的信息，对收益率有着更优的预测能力。

表 4: 单变量基准回归模型结果

|                          | 预测滞后天数 h            |                     |                        |                       |                        |                        |                         |                         |
|--------------------------|---------------------|---------------------|------------------------|-----------------------|------------------------|------------------------|-------------------------|-------------------------|
|                          | 1                   | 7                   | 30                     | 60                    | 90                     | 120                    | 180                     | 360                     |
| <i>VRP</i>               | 0.0001<br>(0.197)   | 0<br>(-0.166)       | 0.0011***<br>(2.918)   | 0.0014***<br>(3.312)  | 0.0014**<br>(2.492)    | -0.0021***<br>(-4.342) | -0.0053***<br>(-6.891)  | -0.0061***<br>(-4.920)  |
| <i>VRP</i> <sup>+</sup>  | -0.0002<br>(-1.231) | -0.0001<br>(-0.551) | 0.0003<br>(1.094)      | 0.0007*<br>(1.820)    | 0.0006<br>(1.190)      | -0.0014***<br>(-4.061) | -0.0026***<br>(-3.949)  | -0.0029**<br>(-2.408)   |
| <i>VRP</i> <sup>-</sup>  | 0.0001<br>(0.796)   | -0.0002<br>(-1.231) | 0.0005*<br>(1.690)     | 0.0004<br>(0.880)     | 0.0009**<br>(2.044)    | -0.0020***<br>(-4.346) | -0.0027***<br>(-4.131)  | -0.0006<br>(-0.646)     |
| <i>IV<sub>MEAN</sub></i> | -0.0012<br>(-1.041) | 0.0056<br>(1.509)   | -0.0116*<br>(-1.950)   | 0.0202**<br>(2.612)   | -0.0135*<br>(-1.810)   | -0.0416***<br>(-4.552) | -0.1238***<br>(-9.235)  | -0.1465***<br>(-8.170)  |
| <i>VOLD</i>              | 0.0008*<br>(1.645)  | 0.0005<br>(0.453)   | -0.0035<br>(-1.393)    | -0.0096**<br>(-2.705) | -0.0103**<br>(-2.852)  | -0.0050<br>(-1.200)    | -0.0018<br>(-0.322)     | 0.0025<br>(0.325)       |
| <i>IVD</i>               | -0.0005<br>(-1.555) | -0.0006<br>(-0.729) | -0.0053***<br>(-3.216) | -0.0051**<br>(-2.022) | -0.0169***<br>(-6.323) | -0.0250***<br>(-8.423) | -0.0398***<br>(-11.586) | -0.0419***<br>(-8.524)  |
| <i>IVDN</i>              | -0.0006<br>(-1.417) | -0.0001<br>(-0.084) | -0.0044**<br>(-2.134)  | -0.0038<br>(-1.183)   | -0.0148***<br>(-4.540) | -0.0222***<br>(-6.316) | -0.0357***<br>(-9.136)  | -0.0320***<br>(-5.767)  |
| <i>RIV</i>               | -0.0003<br>(-0.323) | 0.0003**<br>(2.703) | -0.0006<br>(-0.577)    | -0.0011<br>(-0.800)   | -0.0007<br>(-0.536)    | 0.0023<br>(1.575)      | 0.0142***<br>(6.490)    | 0.0149***<br>(4.718)    |
| <i>VIX</i>               | 0<br>(0.333)        | 0.0001<br>(0.682)   | 0.0013***<br>(3.576)   | 0.0013**<br>(2.107)   | 0.0028***<br>(6.954)   | 0<br>(-0.060)          | -0.0135***<br>(-11.932) | -0.0112***<br>(-12.302) |
| <i>VIX</i> <sup>+</sup>  | 0.0001<br>(0.935)   | -0.0001<br>(-0.390) | 0.0013***<br>(2.920)   | 0.0015**<br>(2.133)   | 0.0039***<br>(7.346)   | 0.0001<br>(0.130)      | -0.0142***<br>(-11.173) | -0.0108***<br>(-9.188)  |
| <i>VIX</i> <sup>-</sup>  | 0.0001<br>(0.660)   | 0<br>(-0.004)       | 0.0010***<br>(2.775)   | 0.0005<br>(0.963)     | 0.0014**<br>(2.900)    | -0.0009<br>(-1.438)    | -0.0087***<br>(-11.843) | -0.0043***<br>(-3.472)  |

\*  $p < 0.1$ , \*\*  $p < 0.05$ , \*\*\*  $p < 0.01$ , 下同



### 4.3 多变量基准模型的实证分析

为挖掘变量对收益率预测的交互作用，本节采用了跨期的多元回归模型。基准模型如下：

$$return_{t,t+h} = \alpha_0 + \alpha_1 VRP_t + \sum \alpha_i Control_{i,t} + \varepsilon_{t,t+h} \quad (14)$$

其中， $return_{t,t+h}$  代表资产在  $t$  时刻至  $t+h$  时刻的收益率， $VRP$  是  $t$  时刻的波动率风险溢价， $Control_{i,t}$  是不同的控制变量， $\varepsilon_{t,t+h}$  为误差项。考虑到变量之间可能存在的多重共线性，本部分以前文中相关性系数矩阵为依据，在此处仅保留  $VRP$ 、 $IV_{MEAN}$ 、 $VOL_{DIFF}$ 、 $IV_{DIFF}$  与  $VIX$  作为多元回归的变量。

表5汇报了多元回归的结果。由表中结果可以看出，在预测期限为 30 日以上时， $VRP$  就可以保持在 1% 水平上显著，且在 30 日、90 日、180 日期限上达到 1% 水平显著 ( $p < 0.01$ )，且  $VRP$  在 30 日至 90 日期限上呈正向预测能力，在 120 日及以上变为负向，这也与现存的部分研究结论重合。对于其余的控制变量， $IV_{MEAN}$  在 7 日的短期水平、以及 60 日至 120 日的中长期水平上表现出显著的正向预测能力，但在长期上失效。 $IV_{DIFF}$  从 7 日开始就在 1% 水平上有显著的负向预测能力。这表明，根据期权隐含波动率计算的不同指标在不同程度、不同期限上都对标的物收益率有一定预测能力。

此外，模型的调整后  $R^2$  会随着预测期限拉长而增加，并在 180 日达到最大值，此后开始降低。这也进一步说明，虽然  $VRP$  总是在长期上具有显著的预测能力，但是根据  $VRP$  对标的资产收益率的预测能力在半年期附近达到最优水平。

表 5: 多元回归模型结果

|             | 预测滞后天数 h            |                        |                        |                        |                        |                        |                         |                        |
|-------------|---------------------|------------------------|------------------------|------------------------|------------------------|------------------------|-------------------------|------------------------|
|             | 1                   | 7                      | 30                     | 60                     | 90                     | 120                    | 180                     | 360                    |
| $VRP$       | 0.0001<br>(0.266)   | -0.0001<br>(-0.523)    | 0.0014***<br>(4.351)   | 0.0011***<br>(2.806)   | 0.0017***<br>(3.782)   | -0.0015***<br>(-3.094) | -0.0030***<br>(-3.909)  | -0.0029***<br>(-2.613) |
| $IV_{mean}$ | 0.0004<br>(0.238)   | 0.0213***<br>(3.912)   | 0.0055<br>(0.614)      | 0.0707***<br>(4.680)   | 0.0629***<br>(4.173)   | 0.0756***<br>(4.678)   | 0.0055<br>(0.276)       | -0.0306<br>(-1.114)    |
| $VOLD$      | 0.0008*<br>(1.695)  | 0.0007<br>(0.552)      | -0.0027<br>(-1.091)    | -0.0093***<br>(-2.671) | -0.0101***<br>(-2.881) | -0.0051<br>(-1.270)    | -0.0039<br>(-0.826)     | -0.0004<br>(-0.061)    |
| $IVD$       | -0.0007<br>(-1.528) | -0.0049***<br>(-3.736) | -0.0106***<br>(-4.590) | -0.0178***<br>(-4.072) | -0.0310***<br>(-6.255) | -0.0374***<br>(-6.512) | -0.0215***<br>(-3.630)  | -0.0314***<br>(-3.517) |
| $VIX$       | 0.0001<br>(0.628)   | 0.0000<br>(0.135)      | 0.0021***<br>(5.324)   | 0.0006<br>(0.919)      | 0.0029***<br>(5.949)   | 0.0007<br>(0.972)      | -0.0116***<br>(-10.298) | -0.0079***<br>(-7.453) |
| $adj. R^2$  | 0.0024              | 0.0094                 | 0.0404                 | 0.0276                 | 0.0679                 | 0.0759                 | 0.2653                  | 0.1404                 |

## 4.4 多变量 VRP 分解模型

在前文的单变量模型中，我们已经得出结论：分解后的 VRP 依旧具备对收益率的解释能力，并在正负之间存在着一定的不对称性。在本节中，我们将进一步挖掘经过正负分解构造出的 VRP 在多元模型中对收益率的解释能力。表6展示了在进行 VRP 分解下的模型结果。通过表中结果可以看出，在对 VRP 进行分解后， $VRP^-$  和  $VRP^+$  分别在不同预测期限上展现出了其预测能力： $VRP^-$  在 30 日期限上表现出正向的 10% 水平显著，之后则是在 120 日即 180 日水平上表现出负向的 1% 水平的显著；而  $VRP^+$  则是在 60 日与 90 日期限分别在 5% 与 10% 显著性水平上有着正向预测的能力。VRP 分解多元回归的模型结果进一步展现了  $VRP^-$  和  $VRP^+$  在收益率预测上的不对称性，这种不对称性不单单存在于预测方向上，更存在于预测的期限上。

表 6: VRP 分解模型结果

|             | 预测滞后天数 h            |                        |                        |                        |                        |                        |                         |                        |
|-------------|---------------------|------------------------|------------------------|------------------------|------------------------|------------------------|-------------------------|------------------------|
|             | 1                   | 7                      | 30                     | 60                     | 90                     | 120                    | 180                     | 360                    |
| $VRP^-$     | 0.0001<br>(1.185)   | -0.0002<br>(-1.046)    | 0.0006*<br>(1.866)     | -0.0002<br>(-0.437)    | 0.0008<br>(1.593)      | -0.0013***<br>(-2.720) | -0.0019***<br>(-3.112)  | 0.0006<br>(0.711)      |
| $VRP^+$     | 0.0000<br>(0.105)   | -0.0000<br>(-0.379)    | 0.0002<br>(1.054)      | 0.0007**<br>(2.178)    | 0.0006*<br>(1.658)     | -0.0006<br>(-1.425)    | -0.0011<br>(-1.591)     | -0.0014<br>(-1.235)    |
| $IV_{mean}$ | 0.0004<br>(0.173)   | 0.0217***<br>(3.978)   | 0.0062<br>(0.677)      | 0.0698***<br>(4.608)   | 0.0624***<br>(4.115)   | 0.0764***<br>(4.729)   | 0.0096<br>(0.476)       | -0.0302<br>(-1.113)    |
| $VOLD$      | 0.0008*<br>(1.715)  | 0.0006<br>(0.497)      | -0.0028<br>(-1.103)    | -0.0095***<br>(-2.696) | -0.0100***<br>(-2.846) | -0.0054<br>(-1.339)    | -0.0043<br>(-0.913)     | -0.0001<br>(-0.015)    |
| $IVD$       | -0.0007<br>(-1.223) | -0.0050***<br>(-3.870) | -0.0102***<br>(-4.389) | -0.0170***<br>(-3.894) | -0.0303***<br>(-6.139) | -0.0376***<br>(-6.583) | -0.0233***<br>(-3.926)  | -0.0328***<br>(-3.744) |
| $VIX$       | 0.0001<br>(0.771)   | 0.0000<br>(0.113)      | 0.0021***<br>(5.326)   | 0.0007<br>(0.997)      | 0.0030***<br>(6.047)   | 0.0006<br>(0.740)      | -0.0119***<br>(-10.617) | -0.0082***<br>(-7.917) |
| $adj. R^2$  | 0.0053              | 0.0103                 | 0.0317                 | 0.0250                 | 0.0642                 | 0.0795                 | 0.2649                  | 0.1332                 |

# 5 基于 HAR 模型的 VRP 研究的实证分析

## 5.1 HAR-RV 模型

异质自回归已实现波动率模型（Heterogeneous Autoregressive model for Realized Volatility, HAR-RV）是由 Corsi 于 2009 年提出的一种用于金融资产高频数据波动率建模与预测的经典模型。该模型基于异质市场假说，认为市场由不同交易频率的投资者构成（如高频交易者、日间交易者、长期机构投资者），不同投资者的行为形成了不同

时间尺度上的波动率成分。模型通过不同时间跨度已实现波动率的线性叠加，来刻画波动率的长记忆性（长期依赖）。本文使用了一般形式的 HAR-RV 模型，其基本形式如下：

$$RV_{t+1} = \beta_0 + \beta_d RV_t + \beta_w \left( \frac{1}{5} \sum_{i=0}^4 RV_{t-i} \right) + \beta_m \left( \frac{1}{22} \sum_{i=0}^{21} RV_{t-i} \right) + \varepsilon_{t+1} \quad (15)$$

其中， $\beta_d$ 、 $\beta_w$ 、 $\beta_m$  分别为日度、周度、月度的已实现波动率估计系数。HAR-RV 作为兼顾简洁性与预测精度的波动率预测模型，通过多时间尺度叠加，可以有效模拟 RV 缓慢衰减的自相关性。在本节的内容中，将以 HAR-RV 模型预测出的 RV 进行 VRP 的计算，相关的变量定义如表7所示：

表 7: HAR-RV 相关变量定义

| 变量名称       | 变量符号     | 公式定义                |
|------------|----------|---------------------|
| HAR-VRP    | $HVRP$   | $IV - RV_{HAR}$     |
| 正向 HAR-VRP | $HVRP^+$ | $IV^+ - RV_{HAR}^+$ |
| 负向 HAR-VRP | $HVRP^-$ | $IV^- - RV_{HAR}^-$ |

## 5.2 单变量 HAR-VRP 模型

为挖掘 HAR-RV 模型在 VRP 构建与对收益率预测中的作用，本部分基于式13进行了单变量回归。表8汇报了 HAR-VRP 模型的结果。可以看到， $HVRP$  在 120 日以上的期限开始展现出 1% 水平上的显著性，在 360 日的超长期限上降低到 5% 水平的显著性，在此处的表现不及普通  $VRP$ 。而对于  $HVRP$  的分解形式  $HVRP^+$  与  $HVRP^-$ ，则是展现出和普通的  $VRP^+$ 、 $VRP^-$  相似的结果：即在 120 日开始可以在 1% 水平上显著，负向分解在 360 日的超长期上显著性开始衰减，而正向分解则依旧能保持一定的显著性水平。

## 5.3 多变量 HAR-VRP 模型

与一般的 VRP 多元回归模型类似，我们通过加入了部分控制变量，挖掘  $HVRP$  的预测能力。在控制变量的选择上，和多变量基准回归保持一致。下式展示了 HAR-VRP

表 8: HAR-RV 单变量回归结果

|                          | 预测滞后天数 h          |                     |                     |                     |                     |                        |                         |                        |
|--------------------------|-------------------|---------------------|---------------------|---------------------|---------------------|------------------------|-------------------------|------------------------|
|                          | 1                 | 7                   | 30                  | 60                  | 90                  | 120                    | 180                     | 360                    |
| <i>HVRP</i>              | 0.0001<br>(0.259) | -0.0001<br>(-0.965) | 0.0003<br>(1.285)   | 0.0006<br>(1.924)   | 0.0007<br>(1.457)   | -0.0015***<br>(-4.594) | -0.0027***<br>(-4.459)  | -0.0022**<br>(-2.161)  |
| <i>HVRP</i> <sup>+</sup> | 0.0001<br>(0.344) | -0.0003<br>(-1.361) | 0.0011**<br>(2.350) | 0.0018**<br>(2.513) | 0.0025**<br>(2.265) | -0.0033***<br>(-4.628) | -0.0147***<br>(-11.718) | -0.0110***<br>(-7.674) |
| <i>HVRP</i> <sup>-</sup> | 0.0001<br>(1.687) | -0.0001<br>(-0.594) | 0.0007**<br>(1.964) | 0.0002<br>(0.311)   | 0.0012**<br>(2.264) | -0.0030***<br>(-4.687) | -0.0066***<br>(-7.415)  | -0.0018<br>(-1.406)    |

所使用的多变量回归模型。

$$return_{t,t+h} = \alpha_0 + \alpha_1 HVRP_t + \sum \alpha_i Control_{i,t} + \varepsilon_{t,t+h} \quad (16)$$

表9展示了使用 *HVRP* 代替普通 *VRP* 后,其在收益率预测方面的表现。由表中结果可以看出, *HVRP* 自 30 日期限起,便可以维持在 1% 水平上的显著性。此外,  $IV_{mean}$  在 60 日至 120 日的期限上有显著的预测能力,但是在预测期限更长或更短时,并不能维持其显著性水平。*VOLD* 则是在 60 日 (5% 水平) 和 90 日 (1% 水平) 的期限上表现出一定的预测能力,其余时候基本丧失预测能力。*IVD* 和 *VIX* 则呈现出和基准多变量回归几乎一致的性质。

此外,通过对比表中汇报的已调整  $R^2$  可以看到,模型整体的拟合优度和基准模型有着相同的规律,都是在 180 日期限处达到最优,并在更长期限时拟合优度下降。而横向对比两种模型,可以发现将 *VRP* 替换为 *HVRP* 后,模型在 60 日及以上期限时的拟合优度均有一定程度上的提升。图??统一对比了两种模型的已调整  $R^2$  上的差异。

#### 5.4 多变量 HAR-VRP 分解模型

类似于4.4部分中的内容,在本节中我们同样对 *HVRP* 分解后的 *HVRP*<sup>+</sup> 与 *HVRP*<sup>-</sup> 进行多元回归分析,以挖掘 *HVRP* 再分解过后是否和一般的 *VRP* 具有类似的表现,是否会对收益率的解释和预测有着更加优秀的效果。10展示了 *HVRP* 经分解后多元回归模型的结果。从其中可以看出, *HVRP*<sup>+</sup> 在 60 日、90 日的期限上分别在 1% 和 5% 的显著性水平上对收益率有正向预测作用,这个效果在 120 日时变为 10% 显著性的负向预测;而 *HVRP*<sup>-</sup> 则是在 120 日与 180 日的期限上,分别在 1% 和 10% 的显著水平上有负向预测能力。通过和4.4的部分对比不难看出,对 *HVRP* 的分解呈现了和 *VRP* 分解十分相似的结果:正向分解在 60 日至 90 日的中长期上有比较显著的正向预测能力,

而负向分解在 120 日至 180 日的长预期上有负向预测能力。

表 9: HVRP 多元回归模型结果

|                          | 预测滞后天数 $h$          |                        |                        |                        |                        |                        |                         |                         |
|--------------------------|---------------------|------------------------|------------------------|------------------------|------------------------|------------------------|-------------------------|-------------------------|
|                          | 1                   | 7                      | 30                     | 60                     | 90                     | 120                    | 180                     | 360                     |
| <i>HVRP</i>              | 0.0001<br>(0.329)   | -0.0001<br>(-1.100)    | 0.0005***<br>(2.715)   | 0.0007***<br>(2.853)   | 0.0012***<br>(3.695)   | -0.0009***<br>(-2.965) | -0.0027***<br>(-5.109)  | -0.0021***<br>(-2.690)  |
| <i>IV<sub>mean</sub></i> | 0.0003<br>(0.135)   | 0.0225***<br>(4.124)   | 0.0030<br>(0.327)      | 0.0901***<br>(5.965)   | 0.0845***<br>(5.672)   | 0.1002***<br>(6.269)   | 0.0241<br>(1.171)       | -0.0564**<br>(-2.058)   |
| <i>VOLD</i>              | 0.0008*<br>(1.681)  | 0.0007<br>(0.551)      | -0.0034<br>(-1.349)    | -0.0086**<br>(-2.504)  | -0.0094***<br>(-2.718) | -0.0049<br>(-1.229)    | -0.0035<br>(-0.738)     | -0.0025<br>(-0.338)     |
| <i>IVD</i>               | -0.0007<br>(-1.352) | -0.0052***<br>(-3.979) | -0.0088***<br>(-3.636) | -0.0264***<br>(-6.514) | -0.0408***<br>(-8.784) | -0.0484***<br>(-8.883) | -0.0284***<br>(-4.603)  | -0.0213**<br>(-2.504)   |
| <i>VIX</i>               | 0.0001<br>(1.098)   | -0.0000<br>(-0.106)    | 0.0020***<br>(5.014)   | 0.0013**<br>(1.977)    | 0.0038***<br>(8.022)   | 0.0010<br>(1.323)      | -0.0121***<br>(-10.430) | -0.0098***<br>(-10.244) |
| adj. $R^2$               | 0.0041              | 0.0110                 | 0.0256                 | 0.0499                 | 0.1105                 | 0.1131                 | 0.2765                  | 0.1554                  |

## 6 不同模型之间的比较

为进一步探寻前文的几种模型在不同预测期限上的优劣，本章将利用不同模型对前文所提到的几种模型的预测能力进行对比。

### 6.1 样本外检验

在本节中，我们将对前文所涉及到的模型进行样本外的检验。对于所采用的数据，我们将时序上前 80% 的数据作为训练集，后 20% 的数据作为测试集。而样本外检验所采用统计量为 MSE 以及  $R^2$ ，其具体计算如下：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (17)$$

$$R^2 = 1 - \frac{MSE_{model}}{MSE_{benchmark}} \quad (18)$$

其中，因为模型的预测是针对一段时间内的累计收益率，因此  $y_i$  和  $MSE_{benchmark}$  也同样是一定时间内的累计收益率： $y_i$  为过去期限内的累计收益率， $MSE_{benchmark}$  是未来期限内的累计收益率与  $y_i$  的差。表11展示了各个模型在不同预测期限上的预测性能。从表中数据可以看出，模型 MSE 总体上会随着预测期限的延长而持续变大，而模型的

表 10: HVRP 分解模型结果

|             | 预测滞后天数 $h$          |                        |                        |                        |                        |                        |                        |                        |
|-------------|---------------------|------------------------|------------------------|------------------------|------------------------|------------------------|------------------------|------------------------|
|             | 1                   | 7                      | 30                     | 60                     | 90                     | 120                    | 180                    | 360                    |
| $HVRP^+$    | 0.0002<br>(0.906)   | -0.0003<br>(-1.053)    | 0.0006<br>(1.182)      | 0.0026***<br>(4.177)   | 0.0017**<br>(2.516)    | -0.0018*<br>(-1.881)   | -0.0002<br>(-0.160)    | -0.0028<br>(-1.462)    |
| $HVRP^-$    | -0.0000<br>(-0.156) | 0.0001<br>(0.238)      | 0.0005<br>(1.190)      | -0.0001<br>(-0.222)    | 0.0007<br>(1.148)      | -0.0021***<br>(-2.825) | -0.0018*<br>(-1.790)   | 0.0016<br>(1.172)      |
| $IV_{mean}$ | 0.0003<br>(0.172)   | 0.0224***<br>(4.100)   | 0.0043<br>(0.472)      | 0.0910***<br>(5.958)   | 0.0876***<br>(5.757)   | 0.0978***<br>(6.239)   | 0.0207<br>(1.006)      | -0.0612**<br>(-2.217)  |
| $VOLD$      | 0.0008<br>(1.636)   | 0.0007<br>(0.591)      | -0.0037<br>(-1.481)    | -0.0090***<br>(-2.617) | -0.0099***<br>(-2.870) | -0.0046<br>(-1.164)    | -0.0031<br>(-0.658)    | -0.0028<br>(-0.378)    |
| $IVD$       | -0.0007<br>(-1.257) | -0.0052***<br>(-4.027) | -0.0089***<br>(-3.728) | -0.0268***<br>(-6.600) | -0.0410***<br>(-8.727) | -0.0475***<br>(-8.878) | -0.0295***<br>(-4.796) | -0.0210**<br>(-2.465)  |
| $VIX$       | 0.0001<br>(0.346)   | 0.0000<br>(0.225)      | 0.0016***<br>(4.287)   | 0.0007<br>(1.008)      | 0.0029***<br>(6.156)   | 0.0022***<br>(3.240)   | -0.0111***<br>(-8.944) | -0.0090***<br>(-7.327) |
| $adj. R^2$  | 0.0041              | 0.0102                 | 0.0239                 | 0.0569                 | 0.1063                 | 0.1219                 | 0.2626                 | 0.1505                 |

$R^2$  却在  $h=7, 60, 120$  时, 并没有在时间期限上表现出递减的规律, 而当  $h=360$  时,  $R^2$  就已经变为负数, 这也能说明虽然模型预测能力会随着预测期限变长整体呈现递减趋势, 但是在 120 日以内, 都可以保持不错的预测效能。此外, 在不同的期限内, 各个模型之间的 MSE 以及  $R^2$  并不存在显著差异, 模型间的差异将在后文中继续比较。

## 6.2 MCS 与 DM 检验

Diebold-Mariano(DM) 检验是一种用于比较两个预测模型预测精度是否存在显著差异的统计方法。其核心思想是: 计算两个模型在样本外预测期间的预测误差之差, 检验该误差差的均值是否显著异于零。如果两个模型的预测精度相同, 则误差差的均值应接近于零; 若显著偏离零, 则说明两个模型的预测能力存在显著差异。在判断优劣时, 结合 DM 统计量的符号与 p 值: 当 p 值显著且 DM 统计量为负时, 说明第一个模型显著优于第二个模型; 当 p 值显著且 DM 统计量为正时, 则第二个模型显著优于第一个模型。

表12展示了 DM 检验的结果。可以看到仅在预测期限为 360 日时, 模型 2、3、4 之间有显著的优劣关系。而在其他期限下, 仅有在  $h=7, 60, 120$  时, 模型 4 显著优于模型 3, 在  $h=180$  时, 有模型 4、模型 3 均优于模型 2, 除此之外模型之间并没有显著的差别。这也与样本外 MSE 和  $R^2$  的结果相符, 即在大部分时候, 这四个模型间并不存在显著区别。

表 11: 样本外预测性能比较

| $h$ | 模型   | MSE      | $R_{OOS}^2$ |
|-----|------|----------|-------------|
| 1   | 模型 1 | 0.000197 | 0.444       |
|     | 模型 2 | 0.000188 | 0.468       |
|     | 模型 3 | 0.000181 | 0.479       |
|     | 模型 4 | 0.000203 | 0.426       |
| 7   | 模型 1 | 0.001812 | 0.544       |
|     | 模型 2 | 0.001819 | 0.542       |
|     | 模型 3 | 0.001791 | 0.549       |
|     | 模型 4 | 0.001830 | 0.540       |
| 30  | 模型 1 | 0.007832 | 0.418       |
|     | 模型 2 | 0.007830 | 0.418       |
|     | 模型 3 | 0.007507 | 0.442       |
|     | 模型 4 | 0.007602 | 0.435       |
| 60  | 模型 1 | 0.012621 | 0.427       |
|     | 模型 2 | 0.012664 | 0.425       |
|     | 模型 3 | 0.012510 | 0.434       |
|     | 模型 4 | 0.012713 | 0.423       |
| 90  | 模型 1 | 0.015831 | 0.220       |
|     | 模型 2 | 0.015803 | 0.221       |
|     | 模型 3 | 0.015628 | 0.232       |
|     | 模型 4 | 0.015250 | 0.248       |
| 120 | 模型 1 | 0.020822 | 0.229       |
|     | 模型 2 | 0.020725 | 0.233       |
|     | 模型 3 | 0.020804 | 0.234       |
|     | 模型 4 | 0.021108 | 0.219       |
| 180 | 模型 1 | 0.037226 | 0.106       |
|     | 模型 2 | 0.037305 | 0.104       |
|     | 模型 3 | 0.037077 | 0.110       |
|     | 模型 4 | 0.037895 | 0.090       |
| 360 | 模型 1 | 0.040831 | -0.184      |
|     | 模型 2 | 0.040299 | -0.169      |
|     | 模型 3 | 0.037619 | -0.091      |
|     | 模型 4 | 0.036898 | -0.070      |

注: 模型 1 为  $VRP$ , 模型 2 为正负分解的  $VRP$ , 模型 3 为  $HVRP$ ; 模型 4 为正负分解的  $HVRP$ , 下同



表 12: DM 检验结果

| 比较对          | $h$               |                                 |                   |                                 |                  |                                 |                                 |                                 |
|--------------|-------------------|---------------------------------|-------------------|---------------------------------|------------------|---------------------------------|---------------------------------|---------------------------------|
|              | 1                 | 7                               | 30                | 60                              | 90               | 120                             | 180                             | 360                             |
| 模型 1 vs 模型 2 | -0.985<br>(0.163) | -1.553<br>(0.061)               | -0.529<br>(0.299) | 1.174<br>(0.879)                | 0.371<br>(0.645) | 1.812<br>(0.964)                | 3.066<br>(0.999)                | -0.649<br>(0.259)               |
| 模型 1 vs 模型 3 | -1.645<br>(0.051) | -0.345<br>(0.365)               | 1.284<br>(0.900)  | 5.366<br>(0.999)                | 3.370<br>(0.999) | 5.666<br>(0.999)                | -1.148<br>(0.126)               | <b>-6.194</b><br><b>(0.000)</b> |
| 模型 1 vs 模型 4 | -0.805<br>(0.211) | -1.222<br>(0.111)               | 2.141<br>(0.983)  | 4.164<br>(0.999)                | 4.540<br>(0.999) | 1.741<br>(0.959)                | -0.147<br>(0.441)               | <b>-6.540</b><br><b>(0.000)</b> |
| 模型 2 vs 模型 3 | 0.637<br>(0.738)  | 1.811<br>(0.964)                | 1.370<br>(0.914)  | 5.257<br>(0.999)                | 2.763<br>(0.997) | 1.123<br>(0.869)                | <b>-3.364</b><br><b>(0.000)</b> | <b>-3.449</b><br><b>(0.000)</b> |
| 模型 2 vs 模型 4 | -0.107<br>(0.458) | 1.648<br>(0.950)                | 2.475<br>(0.993)  | 3.929<br>(0.999)                | 4.177<br>(0.999) | -0.352<br>(0.363)               | <b>-3.401</b><br><b>(0.000)</b> | <b>-4.233</b><br><b>(0.000)</b> |
| 模型 3 vs 模型 4 | -0.645<br>(0.260) | <b>-2.208</b><br><b>(0.014)</b> | 0.268<br>(0.605)  | <b>-2.110</b><br><b>(0.018)</b> | 0.337<br>(0.632) | <b>-1.826</b><br><b>(0.035)</b> | 1.586<br>(0.943)                | <b>-2.879</b><br><b>(0.002)</b> |

表中数字为 DM 统计量, 括号内为  $p$  值。加粗表示在 5% 水平上显著。

模型置信集 (Model Confidence Set, MCS) 一种用于比较多个预测模型表现的方法。与传统的两两比较方法不同, MCS 能够同时评估多个模型的预测能力, 并在给定的置信水平下筛选出一个包含“最优”模型的集合。MCS 检验的基本思想是: 从一个包含所有候选模型的初始集合出发, 通过一系列显著性检验, 逐步剔除表现显著较差的模型, 直到剩余模型的预测能力在统计上没有显著差异。最终保留的模型集合称为“模型置信集”, 在该置信水平下, 集合内每个模型与集合中表现最好的模型具有相同的预测能力。MCS 检验主要基于 bootstrap 方法计算  $p$  值。在每一轮剔除过程中, 算法识别出当前集合中表现最差的模型 (即与其他模型差异最大的模型), 并检验其是否显著劣于其他模型。若  $p$  值小于预设的显著性水平 (通常为 0.05), 则剔除该模型并进入下一轮; 否则停止剔除, 剩余模型构成最优模型集。与传统的 DM 检验相比, MCS 的优势在于: 一是能够同时处理多个模型的比较, 避免了多重检验问题; 二是不需要指定基准模型, 检验结果更加稳健。

表13展示了各个期限下模型的比较, 可以看到在每个期限下进行检验时, MCS 检验均在剔除第一个模型时便停止, 因此每行均只有一个值不为 1。而每次被提出的模型其  $p$  值也远大于所设定的显著性水平, 这也进一步说明, 各个模型在对收益率进行样本外预测时, 并没有显著性的差异。



表 13: 模型置信集 (MCS) 检验结果

| $h$ | 模型 1  | 模型 2  | 模型 3  | 模型 4  |
|-----|-------|-------|-------|-------|
| 1   | 1.000 | 0.720 | 1.000 | 1.000 |
| 7   | 1.000 | 1.000 | 1.000 | 0.882 |
| 30  | 1.000 | 1.000 | 1.000 | 0.532 |
| 60  | 1.000 | 0.856 | 1.000 | 1.000 |
| 90  | 1.000 | 1.000 | 1.000 | 0.824 |
| 120 | 1.000 | 0.574 | 1.000 | 1.000 |
| 180 | 1.000 | 0.614 | 1.000 | 1.000 |
| 360 | 1.000 | 1.000 | 0.548 | 1.000 |

注： $p$  值越大表示模型越稳健。

## 7 结论与展望

### 7.1 研究结论

本文基于 2020 年 1 月至 2025 年 10 月上交所华泰柏瑞沪深 300ETF 的 5 分钟高频收益率数据及对应期权日度交易数据，系统考察了波动率风险溢价对该 ETF 收益率的预测能力、期限结构特征及非对称效应，并引入异质自回归已实现波动率模型对 VRP 的构建方式进行了优化。研究得到以下主要结论：

第一，VRP 对沪深 300ETF 收益率具有显著的预测能力，且该能力呈现出明显的期限结构特征。在 30 日至 90 日的中期预测窗口内，VRP 对收益率表现为正向预测效应，意味着当期权市场隐含的波动率风险溢价上升时，标的 ETF 在未来中期维度上倾向于获得更高的收益补偿；而在 120 日及以上的长期预测窗口内，VRP 的预测方向反转为负向，且显著性水平进一步提升至 1% 水平，这一结论在单变量与多变量回归模型中均保持稳健。该期限结构特征表明，投资者通过期权市场表达的波动风险定价信息在中期和长期对现货收益的作用机理存在本质差异，中期更多地反映风险补偿逻辑，而长期则可能隐含了均值回复与市场情绪校正的复合效应。

第二，正向与负向 VRP 对收益率的预测效应存在显著的非对称性。分解结果显示，正向 VRP 在 120 日及以上的长期预测窗口内对收益率具有稳定的负向预测能力，而负向 VRP 的预测能力在 360 日超长期窗口出现显著衰减，表明下行波动率风险溢价所包含的市场信息在超长期限内已大部分被定价消化。这一发现印证了我国沪深 300ETF 市场中上行与下行波动风险定价机制的非对称性，下行波动风险溢价的预测信息衰减速度更快，可为投资者的差异化择时策略提供参考。

第三，基于 HAR-RV 模型优化构建的 HAR-VRP 指标在多元回归框架下的预测表

现优于传统 VRP。对比结果显示,引入 HAR-RV 进行波动率预测后,多元回归模型在 60 日及以上各预测期限的调整后  $R^2$  均实现了不同程度的提升,且拟合优度在 180 日期限附近达到峰值。这表明,通过纳入日度、周度、月度多时间尺度的已实现波动率信息, HAR-RV 能够更精准地刻画标的资产的真实波动结构,进而提升 VRP 指标对中长期收益率的预测效力。这一发现为波动率风险溢价的测度优化与资产收益预测方法的改进提供了新的经验证据。

第四,隐含波动率相关变量在长期预测中普遍具有稳健的显著性。无论是本文关注的 VRP 及 HAR-VRP,还是隐含波动率均值、认购认沽期权隐波之差以及 VIX 指数,均在 120 日以上的长期预测窗口中表现出较强的预测能力,且显著性水平较为稳定。相比之下,以交易量为基础的认购认沽期权交易量之差仅在个别中期窗口具有弱预测能力,无法在长期维度上维持有效。这一对比进一步证实,隐含波动率所携带的前瞻性市场预期信息是驱动长期收益预测的核心因素,而交易量类指标所含信息的时效性较短。

第五,样本外检验表明各模型预测能力随期限延长呈递减趋势, $R^2$  在 120 日内能抵抗预测期限的影响而部分上升,在 180 日以内保持正值,360 日转为负值。DM 检验与 MCS 检验结果一致表明,四个模型的样本外预测能力无统计显著差异, HAR-VRP 虽在样本内拟合优度更高,但样本外并未显著优于传统 VRP,提示模型解释力的提升未必转化为持续的预测优势。

## 7.2 研究展望

本文围绕波动率风险溢价对沪深 300ETF 收益率的预测效应进行了较为系统的实证研究,并在模型优化方面进行了初步探索,但仍存在若干值得进一步深化的方向:

其一,在 VRP 影响收益率的传导机制研究方面,本文的实证分析集中于预测效应的存在性、方向性及期限结构检验,对于 VRP 通过何种路径影响标的资产收益率的内在机制分析尚不够深入。未来研究可尝试引入投资者情绪、市场流动性、融资融券约束等中介变量,构建更为完整的传导路径分析框架,进一步厘清波动率风险溢价定价信息向现货市场传导的微观机制。

其二,在波动率预测模型的拓展方面,本文采用了经典的 HAR-RV 模型对已实现波动率进行预测,未来可尝试引入 HAR-RV-CJ 模型进一步区分连续波动与跳跃波动成分,或采用 HARQ、SHAR 等考虑测量误差与结构变化的扩展模型,以期进一步提升波动率预测精度,进而优化 VRP 的构建质量与收益率预测效力。

其三,在样本与标的拓展方面,沪深 300ETF 期权上市运行时间仍相对有限,未来随着样本区间的持续延长与市场微观结构的日趋成熟,可进一步考察不同市场周期阶

段下 VRP 预测能力的时变特征与状态依赖性。同时,伴随中证 500ETF 期权、创业板 ETF 期权等多品种场内期权产品的陆续上市,针对不同市值风格 ETF 的 VRP 预测效应开展横向比较研究,也将有助于更全面地理解我国多层次资本市场中波动率风险定价的共性与差异。

## 参考文献

- [1] Merton, R. C. (1973). An intertemporal capital asset pricing model. *Econometrica*, 41(5), 867–887.
- [2] Andersen, T. G., & Bollerslev, T. (1998). Answering the skeptics: Yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- [3] Kilic, M., & Shaliastovich, I. (2019). Good and bad variance premia and expected returns. *Management Science*, 65(6), 2522–2544.
- [4] Britten-Jones, M., & Neuberger, A. (2000). Option prices, implied price processes, and stochastic volatility. *The Journal of Finance*, 55(2), 839–866.
- [5] Bollerslev, T., Tauchen, G., & Zhou, H. (2009). Expected stock returns and variance risk premia. *The Review of Financial Studies*, 22(11), 4463–4492.
- [6] Bollerslev, T., Patton, A. J., & Quaedvlieg, R. (2014). Good volatility, bad volatility: Signed jumps and the predictability of returns. *Journal of Financial Economics*, 114(3), 516–534.
- [7] Drechsler, I., & Yaron, A. (2011). What’ s vol got to do with it. *The Review of Financial Studies*, 24(1), 1–45.
- [8] Rapach, D. E., Strauss, J. K., & Zhou, G. (2013). International stock return predictability: What is the role of the United States? *The Journal of Finance*, 68(4), 1633–1662.
- [9] Carr, P. P., & Wu, L. (2007). Variance Risk Premia. *SSRN Electronic Journal*.  
<http://www.ssrn.com/abstract=577222>
- [10] Carr, P., & Wu, L. (2009). Variance Risk Premiums. *Review of Financial Studies*, 22(3), 1311–1341.
- [11] Dai, Z., Zhou, H., Wen, F., & He, S. (2020). Efficient predictability of stock return volatility: The role of stock market implied volatility. *The North American Journal of Economics and Finance*, 52, 101174.

- [12] Londono, J. M., & Zhou, H. (2017). Variance risk premiums and the forward premium puzzle. *Journal of Financial Economics*, 124(2), 415–440.
- [13] Bollerslev, T., Marrone, J., Xu, L., & Zhou, H. (2014). Stock Return Predictability and Variance Risk Premia: Statistical Inference and International Evidence. *Journal of Financial and Quantitative Analysis*, 49(3), 633–661.
- [14] Timmermann, A. (2018). Forecasting Methods in Finance. *Annual Review of Financial Economics*, 10(1), 449–479.
- [15] Huang, Z., Liu, H., & Wang, T. (2016). Modeling long memory volatility using realized measures of volatility: A realized HAR GARCH model. *Economic Modelling*, 52, 812–821.
- [16] Qiao, F., Xu, L., Zhang, X., & Zhou, H. (2024). Variance risk premiums in emerging markets. *Journal of Banking & Finance*, 167, 107259.
- [17] Carr, P., & Madan, D. (2001). Towards a Theory of Volatility Trading. In E. Jouini, J. Cvitanic, & M. Musiela (Eds.), *Option Pricing, Interest Rates and Risk Management* (pp. 458–476). Cambridge University Press, Cambridge.
- [18] Corsi, F., Audrino, F., & Renò, R. (2012). HAR Modeling for Realized Volatility Forecasting. In L. Bauwens, C. Hafner, & S. Laurent (Eds.), *Handbook of Volatility Models and Their Applications* (pp. 363–382). Wiley.
- [19] Londono, J. M. (2011). The variance risk premium around the world. *International Finance Discussion Papers*, No. 1035, pp. 1–55.
- [20] Zhou, H. (2018). Variance risk premia, asset predictability puzzles, and macroeconomic uncertainty. *Annual Review of Financial Economics*, 10, 481–497.
- [21] Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- [22] Hansen, P. R., & Shek, H. H. (2010). Realized GARCH. CREATES Research Paper 2010-13, pp. 1–62.

- [23] Li, J., Phillips, P. C. B., Shi, S., & Yu, J. (2022). Weak identification of long memory with implications for volatility modeling. SMU Economics and Statistics Working Paper Series, No. 08-2022, pp. 1-49.
- [24] 陈蓉, 郑振龙. (2009). 波动率风险溢价: 模型与实证. 管理科学学报, 12(4), 112-122.
- [25] 郑振龙, 刘杨树. (2013). 波动率风险溢价与股票收益率预测. 金融研究, (10), 156-170.
- [26] 黄薏舟, 郑振龙. (2016). 无模型隐含波动率及其信息含量——基于沪深 300ETF 期权的实证研究. 金融研究, (11), 159-174.
- [27] 陈国进, 张润泽, 姚定俊. (2018). 尾部风险、波动率风险溢价与股票收益. 金融研究, (10), 112-128.
- [28] 陈蓉, 葛骏, 余军. (2021). 中国股票市场的波动率风险溢价: 基于 ETF 期权的实证. 系统工程理论与实践, 41(5), 1121-1138.